



Pontificia Universidad
JAVERIANA
Bogotá

Predicción de Calidad del Agua en Ríos de la India

*Procesamiento de Datos con PySpark MLlib & Keras sobre Cluster con Apache Spark y
Hadoop HDFS*

Jonatan Alejandro Gallo

Computación de Alto Desempeño

28 de mayo de 2026

Contexto



Pontificia Universidad
JAVERIANA
Bogotá

Problema: El monitoreo de la calidad del agua en los ríos de la India requiere analizar grandes volúmenes de datos fisicoquímicos y microbiológicos provenientes de 534 estaciones distribuidas en 18 estados.

Motivación: Aplicar técnicas de Procesamiento de Alto Volumen de Datos (PAVD) para diagnosticar la calidad hídrica mediante modelos de Machine Learning ejecutados sobre un clúster HPC con Apache Spark.

Infraestructura: Clúster HPC de la Javeriana — Spark 3.5.5, 12 workers, 240 núcleos, 756 GiB RAM, datos almacenados en HDFS.

534

estaciones monitoreadas

18

estados de la India

6

parámetros fisicoquímicos

Objetivos



Pontificia Universidad
JAVERIANA
Bogotá

General

Implementar y comparar múltiples modelos de Machine Learning (Keras, Random Forest, GBT y Regresión Lineal) para predecir el Índice de Calidad del Agua (WQI) en ríos de la India, evaluando su rendimiento mediante métricas estándar.

Específicos

- Cargar y preprocesar datos distribuidos desde HDFS con PySpark SQL.
- Calcular el WQI según la referencia bibliográfica (IntechOpen).
- Visualizar la distribución geoespacial del WQI sobre el mapa de la India.
- Entrenar 4 modelos: Red Neuronal Keras, Random Forest, GBT y Regresión Lineal.
- Evaluar y seleccionar el mejor modelo con MSE, RMSE, MAE y R^2 .

1

Carga HDFS

CSV → Spark DataFrame



2

Preprocesamiento

Cast tipos, nulos, filtrado



3

EDA

Visualización de parámetros



4

Cálculo WQI

Rangos + pesos + suma

5

Mapa India

GeoPandas + shapefile



6

4 Modelos ML

Keras, RF, GBT, LR



7

Evaluación

MSE, RMSE, MAE, R^2



8

Análisis


Hallazgos y conclusiones

Oxígeno Disuelto y pH



Pontificia Universidad
JAVERIANA
Bogotá

Parametro DO y pH de la calidad del Agua — India




DO presenta alta variabilidad con caídas a cero en estaciones críticas. El pH se mantiene ~7.5–8.0 salvo picos alcalinos puntuales.

BOD y Nitratos / Nitritos



Pontificia Universidad
JAVERIANA
Bogotá

Parametro BOD y Nitrogenos de la calidad del Agua — India




El BOD supera 75 mg/L en zonas con alta carga orgánica. Los nitratos/nitritos son bajos en la mayoría de estaciones.

Conductividad y Coliformes Fecales



Pontificia Universidad
JAVERIANA
Bogotá

Parametro Conductividad y Material Fecal de la calidad del Agua — India




FECAL_COLIFORM alcanza 310,417 UFC/100mL — parámetro con mayor variabilidad y poder discriminante del dataset.

Dataset: waterquality.csv

- 534 registros, 11 columnas originales
- 0 valores nulos detectados
- Se eliminó TOTAL_COLIFORM (no aporta al WQI)
- Tipos convertidos de string a FloatType
- FECAL_COLIFORM: rango 0 – 310,417 UFC/100mL

Distribución de calidad del agua



- Baja (50.4%)
- Buena (31.1%)
- Muy Baja (13.3%)
- Excelente (5.2%)

Estadísticas del WQI

Estadístico	Valor
Media	57.957
Desv. est.	15.987
Mínimo	10.120
P25	48.120
Mediana	59.180
P75	70.600
Máximo	95.120

El 63.7% de las estaciones presenta calidad Baja o Muy Baja.

Cálculo del WQI



Pontificia Universidad
JAVERIANA
Bogotá

Fórmula del Índice de Calidad del Agua:

$$WQI = qrPH \times 0.165 + qrDO \times 0.281 + qrCOND \times 0.234 + qrBOD \times 0.009 + qrNN \times 0.028 + qrFecal \times 0.281$$

Parámetro	Peso	Significado
pH	0.165	Acidez/alcalinidad del agua
DO	0.281	Oxígeno disuelto (calidad)
Conductividad	0.234	Capacidad de conducción eléctrica
BOD	0.009	Demanda bioquímica de oxígeno
Nitratos	0.028	Nitratos y nitritos (N)
Fecal Coliform	0.281	Contaminación microbiológica

Clasificación del WQI:

Excelente (0-25)

Buena (25-50)


Baja (50-75)

Muy Baja (75-100)

Mapa del Índice WQI de la India



Pontificia Universidad
JAVERIANA
Bogotá




Rojo oscuro (WQI 75-100): Goa, Maharashtra, Andhra Pradesh. Punjab y norte de Delhi presentan la mejor calidad relativa.

WQI por Estado — Histograma



Pontificia Universidad
JAVERIANA
Bogotá

Histograma de la calidad del Agua de la India



Punjab registra el WQI más bajo (~38). Rajasthan y Madhya Pradesh superan 90. Ningún estado alcanza WQI < 25 (Excelente).


Evaluación y Selección de Modelos



Pontificia Universidad
JAVERIANA
Bogotá

Cuatro modelos entrenados — partición 80/20 con semilla fija (seed=42):

Modelo	MSE	RMSE	MAE	R ²
Regresión Lineal MLib	0.0000	0.0000	0.0000	1.0000
Red Neuronal Keras	0.0300	0.1732	0.0519	0.9999
GBT MLib (adicional)	11.5887	3.4042	0.9444	0.9608
Random Forest MLib	15.7384	3.9672	2.5402	0.9467







Todos los modelos superan $R^2 > 0.94$. La Regresión Lineal alcanza 1.0 porque el WQI es por definición una combinación lineal exacta de los features.

WQI Real vs WQI Predicho (Comparación de 4 Modelos)



Pontificia Universidad
JAVERIANA
Bogotá

WQI Real vs WQI Predicho — Comparacion de Modelos




Keras y Regresión Lineal se superponen con la diagonal perfecta. GBT captura mejor los extremos que Random Forest.

Importancia de Variables



Pontificia Universidad
JAVERIANA
Bogotá



Hallazgo clave

- Coliformes fecales (qrFecal) concentra el 44-49% de la importancia en ambos modelos.
- Oxígeno disuelto (qrDO) ocupa el segundo lugar con 29-31%.
- Nitratos (qrNN) aporta < 0.2%, casi irrelevante para la predicción del WQI.

Análisis y Hallazgos



Pontificia Universidad
JAVERIANA
Bogotá

Regresión Lineal = R^2 perfecto

El WQI es una suma ponderada exacta de los features
→ la RL recupera los coeficientes originales con error
 ~ 0 . Esto valida la correcta implementación del pipeline.

Red Neuronal Keras: $R^2 = 0.9999$

200 épocas, loss entrenamiento 0.0005, validación
0.0228. La brecha sugiere leve sobreajuste, pero la
generalización es excelente. Valida integración
TensorFlow + Spark.

GBT > Random Forest en ensambles

GBT (RMSE 3.40, R^2 0.9608) supera a RF (RMSE 3.97, R^2
0.9467). La corrección secuencial de residuos del GBT
captura mejor los extremos del WQI.

63.7% del agua es de calidad Baja o Muy Baja

Solo 28 de 534 estaciones (5.2%) alcanzan calidad
Excelente. El deterioro hídrico es generalizado en los
ríos monitoreados de la India.

Recomendaciones



Pontificia Universidad
JAVERIANA
Bogotá

- 1 Usar parámetros fisicoquímicos originales (valores continuos) como features para que los modelos no lineales muestren ventajas reales.
- 2 Priorizar intervenciones de saneamiento en FECAL_COLIFORM — el parámetro con mayor impacto (44-49%) en el WQI.
- 3 Escalar el dataset con series históricas mensuales para justificar el uso completo del clúster de 12 workers sobre HDFS.
- 4 Encapsular el flujo en un MLlib Pipeline serializable (VectorAssembler + modelo) para despliegue en producción.
- 5 Persistir los modelos entrenados en HDFS para reutilización sin reentrenamiento en iteraciones futuras.

Conclusiones



Pontificia Universidad
JAVERIANA
Bogotá

1. El 63.7% de las 534 estaciones presenta calidad Baja o Muy Baja — el recurso hídrico requiere atención prioritaria en saneamiento y control de vertimientos.
2. Coliformes fecales domina la predicción del WQI (44-49% de importancia en RF y GBT), seguido por oxígeno disuelto (29-31%).
3. La Regresión Lineal obtiene $R^2 = 1.0000$ — confirma la relación matemática exacta entre WQI y sus componentes, validando el pipeline de PySpark.
4. GBT es el modelo de ensamble recomendado (RMSE = 3.40, $R^2 = 0.9608$), superando a Random Forest (RMSE = 3.97, $R^2 = 0.9467$).
5. La Red Neuronal Keras ($R^2 = 0.9999$, 200 épocas, loss val. 0.0228) demuestra la viabilidad de integrar TensorFlow con PySpark en el clúster HPC.
6. PySpark MLlib permitió entrenar modelos distribuidos sobre los 12 workers del clúster sin dependencia de sklearn en los nodos.

Referencias



Pontificia Universidad
JAVERIANA
Bogotá

1. Singh, S., & Pant, K. K. (2021). Water Quality Index. IntechOpen. <https://www.intechopen.com/chapters/69568>
2. Apache Spark. (2024). MLlib: Machine Learning Library Guide — Spark 3.5.5. <https://spark.apache.org/docs/3.5.5/ml-guide.html>
3. TensorFlow. (2023, June 8). Keras: The high-level API for TensorFlow. <https://www.tensorflow.org/guide/keras>
4. Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5-32.
5. Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. Annals of Statistics, 29(5), 1189-1232.
6. Maharashtra Pollution Control Board. (2021). Annexure I: Water quality criteria (CPCB). https://mpcb.ecmpcb.in/images/pdf/WaterQuality0709/AnnexureI_WQ.pdf
7. GeoPandas Developers. (2024). GeoPandas Documentation 0.14. <https://geopandas.org/>